

So sánh Transformer Seq2Seq huấn luyện từ đầu với ViT5 trong tóm tắt trừu tượng văn bản tiếng Việt

Đặng Minh Nhật (24022423), Đặng Duy Anh (24021358),

Lưu Xuân Tân (24022447), Trần Đức Thịnh (24022459)

Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội

Học phần Xử lý ngôn ngữ tự nhiên (2526H_INT3406_80)

TÓM TẮT

Nghiên cứu này so sánh bốn hệ thống tóm tắt tin tức tiếng Việt gồm Lead-1, Lead-3, Transformer encoder–decoder huấn luyện từ đầu và checkpoint ViT5 đã được fine-tune. Sau quá trình làm sạch và khử trùng lặp, dữ liệu gồm 246.975 cặp bài báo–tóm tắt; 197.580 mẫu được dùng để huấn luyện, 2.000 mẫu để lựa chọn cấu hình và 2.000 mẫu để kiểm thử. Các hệ thống được đánh giá bằng ROUGE, tỷ lệ nén và mô hình ngôn ngữ lớn đối chiếu trực tiếp đầu ra với văn bản nguồn. Scratch Transformer đạt R-1/R-2/R-L lần lượt là 33,84/17,84/28,30, dẫn đầu cả ba chỉ số ROUGE. Trên 200 mẫu đánh giá bằng mô hình ngôn ngữ lớn, Scratch Transformer có tỷ lệ lỗi nghiêm trọng về tính đúng sự thật thấp hơn ViT5, trong khi ViT5 đạt điểm cao hơn về độ trôi chảy và độ súc tích. Chênh lệch điểm tổng hợp giữa hai mô hình sinh chưa rõ ràng theo khoảng tin cậy bootstrap 95%. Kết quả cho thấy Transformer huấn luyện từ đầu là một đối chứng có tính cạnh tranh và khả năng kiểm soát cao; lựa chọn hệ thống phù hợp phụ thuộc vào mức ưu tiên giữa tương đồng tham chiếu, độ nén, phong cách diễn đạt và tính đúng sự thật.

I. GIỚI THIỆU


Khối lượng tin tức tiếng Việt tăng nhanh làm nảy sinh nhu cầu rút gọn bài báo thành nội dung ngắn, chính xác và dễ đọc. Tóm tắt trích xuất giữ nguyên câu từ văn bản nguồn nên thường có độ trung thực cao, nhưng phụ thuộc mạnh vào cấu trúc bài viết. Tóm tắt sinh, còn gọi là tóm tắt trừu tượng, có thể diễn đạt linh hoạt và súc tích hơn, song có nguy cơ tạo thông tin không xuất hiện trong bài gốc. Vì vậy, một thực nghiệm đáng tin cậy cần đánh giá đồng thời mức tương đồng với tóm tắt tham chiếu, tỷ lệ nén, tính đúng sự thật và khả năng bao phủ nội dung chính.

Nghiên cứu trả lời bốn câu hỏi: (i) Transformer huấn luyện từ đầu và ViT5 khác biệt như thế nào so với Lead-1 và Lead-3 theo ROUGE; (ii) kết luận thay đổi ra sao khi các tóm tắt được chấm trực tiếp theo văn bản nguồn; (iii) tỷ lệ nén giải thích sự đánh đổi giữa độ bao phủ và độ súc tích như thế nào; và (iv) chất lượng tóm tắt tham chiếu ảnh hưởng ra sao đến cách diễn giải ROUGE.

Các đóng góp chính của nghiên cứu gồm: xây dựng Transformer encoder–decoder huấn luyện từ đầu cho tóm tắt tiếng Việt; thiết lập quy trình so

sánh mô hình này với ViT5 và hai hệ thống cơ sở Lead-1, Lead-3 trên cùng tập dữ liệu; đánh giá kết quả bằng ROUGE, tỷ lệ nén và mô hình ngôn ngữ lớn; đồng thời phân tích mối quan hệ giữa mức tương đồng với tóm tắt tham chiếu, tính đúng sự thật, độ bao phủ, độ trôi chảy, độ súc tích và độ dài đầu ra.

Mã nguồn. Kho mã nguồn của nghiên cứu được công bố tại GitHub.



Hình 1. Quy trình tổng quát của bài toán tóm tắt văn bản tiếng Việt.

II. CƠ SỞ PHƯƠNG PHÁP

A. Tóm tắt trích xuất và tóm tắt sinh

Lead-1 và Lead-3 lần lượt lấy câu đầu hoặc ba câu đầu của bài báo, qua đó tận dụng xu hướng thông tin quan trọng thường xuất hiện ở phần mở đầu tin tức. Ngược lại, Scratch Transformer và ViT5 sinh một chuỗi mới theo phân phối xác suất có điều kiện

$$P(\mathbf{y} | \mathbf{x}) = \prod_{t=1}^T P(y_t | y_{<t}, \mathbf{x}). \quad (1)$$

Cách tiếp cận sinh linh hoạt hơn về diễn đạt nhưng có thể làm sai thực thể, số liệu hoặc quan hệ giữa các sự kiện.

B. Cơ chế attention và kiến trúc Transformer

Transformer encoder-decoder mã hóa toàn bộ văn bản nguồn thành biểu diễn ngữ cảnh, sau đó sinh tóm tắt từ trái sang phải. Thành phần trung tâm là attention tích vô hướng có tỷ lệ:

$$S_{\text{attn}} = \frac{QK^T}{\sqrt{d_k}} + M, \quad (2)$$

$$\text{Attn}(Q, K, V; M) = \text{softmax}(S_{\text{attn}})V. \quad (3)$$

Mask M chặn token đệm và, trong decoder, chặn các vị trí tương lai. Multi-head attention thực hiện phép tính này trong nhiều không gian con, còn mạng truyền thẳng tái tổ hợp đặc trưng tại từng vị trí. Scratch Transformer dùng sáu lớp encoder, sáu lớp decoder và cách bố trí Pre-Norm để duy trì đường residual ổn định khi toàn bộ trọng số được học từ đầu [1, 5].

C. Chỉ số đánh giá

ROUGE-1 và ROUGE-2 đo mức trùng khớp unigram và bigram; ROUGE-L dựa trên dãy con chung dài nhất [2]. Tỷ lệ nén (compression ratio, CR) được định nghĩa

$$\text{CR} = \frac{\text{\#từ trong tóm tắt dự đoán}}{\text{\#từ trong văn bản nguồn}} \times 100\%. \quad (4)$$

Điểm tổng hợp của mô hình chấm LLM là

$$S = 0.35F + 0.25C + 0.15R + 0.15L + 0.10N, \quad (5)$$


trong đó F , C , R , L và N lần lượt biểu diễn tính đúng sự thật, độ bao phủ, mức tập trung, độ trôi chảy và độ súc tích. Lỗi nghiêm trọng về tính đúng

sự thật được báo cáo riêng để tránh tính cùng một lỗi hai lần. Các công thức kiến trúc, kích thước tensor và chi tiết tối ưu hóa được tổng hợp trong Phụ lục A.

III. DỮ LIỆU VÀ TIỀN XỬ LÝ

Nguồn dữ liệu. Bộ dữ liệu gốc *News Dataset Vietnamese* được công bố trên Kaggle.

Sau bước làm sạch và khử trùng lặp, tập dữ liệu gồm 246.975 cặp bài báo–tóm tắt. Tập huấn luyện gồm 197.580 mẫu, tương ứng 80% dữ liệu. Từ 49.395 mẫu còn lại, nghiên cứu chọn ngẫu nhiên 2.000 mẫu cho tập xác thực và 2.000 mẫu cho tập kiểm thử; 45.395 mẫu ngoài ba tập này không tham gia thực nghiệm. Quy trình làm sạch gồm: chuẩn hóa Unicode NFC; loại bỏ HTML, URL, ký tự điều khiển và ký tự nhiễu; chuẩn hóa khoảng trắng; giữ các bài báo dài 100–1.200 từ và tóm tắt dài 10–150 từ; sử dụng mô hình embedding paraphrase-multilingual-mpnet-base-v2 [10,11] để tính độ tương đồng cosine; và chỉ giữ các cặp văn bản nguồn–tóm tắt tham chiếu có độ tương đồng từ 0,50 trở lên. Việc khử trùng lặp được thực hiện trước khi chia tập nhằm hạn chế rò rỉ dữ liệu giữa tập huấn luyện, tập xác thực và tập kiểm thử.



Hình 2. Kiến trúc tổng quát Transformer encoder–decoder. Scratch Transformer sử dụng cách bố trí Pre-Norm.

Bảng I. Thống kê mô tả dữ liệu sạch.

Chỉ số	Bài báo	Tóm tắt
Trung bình (từ)	467,6	41,3
Độ lệch chuẩn	217,5	15,8
Trung vị (từ)	432,0	38,0
Min–Max (từ)	100–1.200	10–150

Tỷ lệ nén trung bình của tóm tắt tham chiếu là 10,62%, tương đương độ dài bằng khoảng 1/9,4 văn bản nguồn. Độ tương đồng cosine trung bình đạt 0,706, cho thấy văn bản nguồn và tóm tắt tham chiếu có mức căn chỉnh ngữ nghĩa tương đối tốt sau

bản nguồn và tóm tắt tham chiếu theo mã định danh thay vì theo thứ tự dòng.




Hình 3. Quy trình làm sạch và chuẩn hóa dữ liệu.

khi lọc. Hệ số phân mảnh token (token fertility) có giá trị trung bình xấp xỉ 1,14 và trung vị xấp xỉ 1,13; kết quả này cho thấy phần lớn từ tiếng Việt được biểu diễn bằng khoảng một token. Các ngưỡng 1.200 từ đối với văn bản nguồn và 150 từ đối với tóm tắt tham chiếu được áp dụng ở bước làm sạch theo đơn vị từ. Các ngưỡng này khác với giới hạn token của Scratch Transformer: văn bản nguồn được cắt xuống tối đa 768 token, kể cả EOS; các mẫu huấn luyện có tóm tắt tham chiếu vượt 95 token nội dung bị loại thay vì bị cắt cụt.


Bảng II. Phân chia dữ liệu thực nghiệm.

Tập	Số mẫu	Vai trò
Huấn luyện	197.580	Ước lượng tham số
Xác thực	2.000	Lựa chọn cấu hình
Kiểm thử	2.000	Đánh giá cuối cùng

Tập xác thực chỉ được dùng để lựa chọn cấu hình; tập kiểm thử chỉ được sử dụng sau khi cấu hình đã được cố định. Mỗi mẫu có một mã định danh ổn định; tóm tắt dự đoán được ghép với văn



Hình 4. Phân phối độ dài văn bản nguồn và tóm tắt tham chiếu.



Hình 5. Phân phối độ tương đồng cosine giữa văn bản nguồn và tóm tắt tham chiếu.

IV. HỆ THỐNG VÀ THIẾT KẾ THỰC NGHIỆM

A. Các hệ thống cơ sở Lead

Lead-1 và Lead-3 sử dụng cùng một hàm tách câu, trong đó các trường hợp như tên miền, ngày tháng, số thập phân, chức danh và địa danh viết tắt (ví dụ: TP.HCM) được bảo vệ. Vì hai hệ thống dùng cùng quy trình tiền xử lý, khác biệt giữa chúng chủ yếu phản ánh số câu được trích xuất.

B. Scratch Transformer

Scratch Transformer được cài đặt bằng PyTorch mà không nạp trọng số tiền huấn luyện. Mục tiêu của hệ thống là tạo một đối chứng có thể kiểm soát đầy đủ và đo năng lực học được chỉ từ 197.580 cặp huấn luyện.

Tokenizer SentencePiece Unigram được huấn luyện trên dữ liệu Unicode đã chuẩn hóa và sử dụng bốn token đặc biệt: PAD=0, UNK=1, BOS=2 và EOS=3 [4]. Văn bản nguồn được giới hạn ở 768 token, kể cả EOS. Các mẫu huấn luyện có tóm tắt tham chiếu vượt 95 token nội dung bị loại thay vì cắt nhãn; chuỗi đích còn lại có tối đa 96 vị trí sau khi thêm BOS hoặc EOS. Phép đệm được thực hiện động theo chuỗi dài nhất trong từng mini-batch.

Encoder và decoder dùng chung ma trận embedding $E \in \mathbb{R}^{16000 \times 384}$; ma trận này đồng thời

Bảng III. Cấu hình của Scratch Transformer.

Thành phần	Giá trị
Kiến trúc	Encoder–Decoder, Pre-Norm
Số lớp	6 encoder + 6 decoder
$d_{\text{model}} / d_{\text{ff}}$	384 / 1.536
Số đầu attention	6 ($d_k = 64$)
Tokenizer	SPM Unigram, từ vựng 16.000
Độ dài nguồn/đích	768 / 96 token
Dropout / label smoothing	0,1 / 0,05
Hàm kích hoạt	GELU
Embedding	Chia sẻ và buộc trọng số đầu ra


được buộc với trọng số chiếu đầu ra [12]. Mô hình có 30.991.872 tham số học duy nhất. Pre-Norm, residual connection, mask đệm nguồn, mask đệm đích và mask nhân quả được áp dụng nhất quán trong sáu lớp encoder và sáu lớp decoder.

Mô hình được huấn luyện bằng teacher forcing và cross-entropy với label smoothing 0,05. AdamW sử dụng $(\beta_1, \beta_2) = (0,9, 0,98)$, learning rate cực đại 3×10^{-4} , warmup 3.030 bước, weight decay 0,01 và gradient clipping 1,0 [6]. Hai GPU T4 chạy Distributed Data Parallel với batch toàn cục 64 và mixed precision FP16. Checkpoint tốt nhất xuất hiện ở epoch 17, với hàm mất mát xác thực có label smoothing bằng 2,5539; giá trị

$\exp(2,5539) \approx 12,86$ chỉ được dùng để theo dõi và không được diễn giải là perplexity one-hot chuẩn.

Bảng IV. Cấu hình tối ưu hóa Scratch Transformer.

Siêu tham số	Giá trị
Epoch tối đa / patience	20 / 4
GPU / batch mỗi GPU	2 / 32
Batch toàn cục	64
Optimizer	AdamW
$\beta_1, \beta_2, \epsilon$	0,9; 0,98; 10^{-9}
LR cực đại / cực tiểu	3×10^{-4} / 10^{-6}
Warmup	3.030 bước
Weight decay / gradient clip	0,01 / 1,0
Precision	AMP FP16




Hình 6. Hàm mất mát trên tập huấn luyện và tập xác thực.

Khi suy luận, mô hình chạy encoder một lần rồi sinh tự hồi quy bằng beam search. Cấu hình cuối sử dụng bốn beam, length penalty 1,1, chặn lặp trigram và giới hạn 96 token. PAD và BOS bị cấm ở đầu ra; các phân mảnh dự đoán được hợp nhất theo mã định danh để kiểm tra đủ 2.000 mẫu trước khi đánh giá. Chi tiết tensor, mask, phân rã tham số và quy trình huấn luyện được trình bày trong Phụ lục A.

C. ViT5

ViT5 sử dụng checkpoint VietAI/vit5-base-vietnews-summarization, đã được fine-tune cho tóm tắt tin tức tiếng Việt [8, 9]. Kiến trúc ViT5 kế



Hình 7. Phân phối độ dài token và hệ số phân mảnh của SentencePiece Unigram.

thừa khuôn khổ text-to-text của T5 [3]. Cấu hình cuối cùng sử dụng beam search với bốn beam, length penalty bằng 1,1, no-repeat n-gram size bằng 3 và max_new_tokens=128. Do ViT5 đã được huấn luyện trước và fine-tune trên một tập dữ liệu riêng, kết quả phản ánh hiệu quả của hai hệ thống hoàn chỉnh thay vì chỉ phản ánh khác biệt giữa hai kiến trúc.

D. Lựa chọn cấu hình và giao thức đánh giá

Thiết kế thực nghiệm được tổ chức quanh bốn câu hỏi: (i) Scratch Transformer khác biệt như thế nào so với các hệ thống trích xuất cơ sở; (ii) hệ thống huấn luyện từ đầu khác checkpoint ViT5 đã fine-tune như thế nào; (iii) cấu hình giải mã ảnh hưởng ra sao đến ROUGE và độ dài tóm tắt; và (iv) kết luận trên tập xác thực có được duy trì trên tập kiểm thử độc lập hay không.

Mỗi hệ thống sinh được đánh giá trên tập xác thực trước khi chạy trên tập kiểm thử. Các biến được khảo sát gồm giải mã tham lam hoặc beam search, beam size bằng 4, length penalty thuộc {0,8; 1,0; 1,1}, cơ chế chặn lặp trigram và giới hạn sinh 128 token đối với ViT5. Việc lựa chọn ưu tiên

ROUGE-1/2/L F1, đồng thời xem xét tỷ lệ nén để tránh chọn một cấu hình chỉ vì tạo tóm tắt dài hơn.

Scratch Transformer sử dụng Beam-4, $LP=1,1$ và $NR=3$ vì cấu hình này dẫn đầu R-1 và R-2, mặc dù $LP=0,8$ cao hơn 0,0346 điểm R-L. So với giải mã tham lam, cấu hình được chọn tăng 1,0979 điểm R-1 và 1,2979 điểm R-2. CR tăng từ 8,7365% lên 9,7061%, cho thấy một phần lợi thế ROUGE đi kèm với đầu ra dài hơn. ViT5 sử dụng Beam-4, $LP=1,1$, $NR=3$ và giới hạn 128 token vì cấu hình này dẫn đầu R-1 và R-L; R-2 chỉ thấp hơn cấu hình $LP=1,0$ đúng 0,0057 điểm. Sau bước lựa chọn, hai cấu hình được cố định trước khi chạy trên tập kiểm thử để tránh lựa chọn theo điểm kiểm thử. Kiểm tra nhanh trên 10 mẫu chỉ nhằm xác nhận quy trình và lỗi kỹ thuật, không được dùng để chọn mô hình.

Trước khi tính ROUGE, văn bản được chuẩn hóa Unicode NFC, chuyển thành chữ thường và tách từ bằng `underthesea`. Cả bốn hệ thống đều tạo đủ 2.000 tóm tắt dự đoán hợp lệ. ROUGE đo mức trùng khớp giữa tóm tắt dự đoán và tóm tắt tham chiếu, trong khi mô hình chấm LLM đánh giá mức độ chính xác, đầy đủ, tập trung và dễ đọc khi đối chiếu trực tiếp với văn bản nguồn. Hai nguồn bằng chứng bổ sung cho nhau; không thước đo nào đủ để tự quyết định chất lượng tóm tắt.

Kiểm tra tóm tắt tham chiếu sử dụng văn bản nguồn và tóm tắt tham chiếu để xác định mức độ mỗi thông tin được văn bản nguồn hỗ trợ. Đánh giá hệ thống sử dụng văn bản nguồn cùng bốn tóm tắt ứng viên nhưng không cung cấp tóm tắt tham chiếu. Tên hệ thống được làm mờ; các vị trí A/B/C/D được cân bằng để mỗi hệ thống xuất hiện đúng 50 lần ở từng vị trí trên 200 mẫu. Bốn hệ thống được chấm theo thiết kế ghép cặp trên cùng

mã định danh mẫu; bootstrap cũng được thực hiện theo mã định danh này.

Bảng V. Các cấu hình được đánh giá trên tập xác thực.

Hệ thống	Cấu hình	R-1	R-2	R-L	CR (%)
Scratch	Greedy	33,0618	16,9446	27,5080	8,7365
Scratch	Beam-4, LP=0,8, NR=3	33,7884	18,2143	28,4245	8,4232
Scratch	Beam-4, LP=1,0, NR=3	33,9924	18,1839	28,3486	9,2057
Scratch	Beam-4, LP=1,1, NR=3	34,1597	18,2425	28,3899	9,7061
ViT5	Beam-4, LP=0,8, NR=3	31,1089	14,1935	24,6530	8,7852
ViT5	Beam-4, LP=1,0, NR=3	31,2016	14,2340	24,6987	8,8863
ViT5	Beam-4, LP=1,1, NR=3	31,2495	14,2283	24,7108	8,9242
Hệ cơ sở	Lead-1	25,6098	11,0876	19,6637	11,0935
Hệ cơ sở	Lead-3	24,9105	10,6417	17,5409	29,7882

V. KẾT QUẢ

A. Đánh giá tự động

Bảng VI. Kết quả trên 2.000 mẫu kiểm thử.

Hệ thống	R-1	R-2	R-L	CR (%)
Lead-1	26,78	12,17	20,80	11,51
Lead-3	25,12	11,03	17,92	30,14
Scratch Transformer	33,84	17,84	28,30	9,42
ViT5	31,22	14,51	25,00	8,63

Scratch Transformer dẫn đầu cả ba chỉ số ROUGE. ViT5 đứng thứ hai và có CR thấp nhất. Lead-3 tạo đầu ra dài nhất nhưng không cải thiện ROUGE so với Lead-1; việc thêm hai câu làm tăng lượng nội dung đồng thời đưa vào nhiều phần không trùng với tóm tắt tham chiếu, từ đó làm giảm F1.


B. Chất lượng tóm tắt tham chiếu

Trong 200 mẫu được phân tầng theo độ dài văn bản nguồn, 108 tóm tắt tham chiếu được hỗ trợ đầy đủ, 75 được hỗ trợ một phần, 17 phần lớn không có căn cứ và không có mẫu nào bị ghép sai hoàn toàn. Như vậy, 46,0% tóm tắt tham chiếu có ít nhất một ý cốt lõi không được văn bản nguồn hỗ trợ. Các lỗi thường gặp gồm bổ sung ngày tháng, địa điểm,

số liệu, chức danh hoặc nguồn phát biểu không xuất hiện trong văn bản nguồn. ROUGE vẫn hữu ích khi so sánh các hệ thống trên cùng tập dữ liệu, nhưng không đủ để khẳng định tính đúng sự thật tuyệt đối.

Bảng VII. Kết quả kiểm tra tóm tắt tham chiếu trên 200 mẫu.

Nhãn	Số mẫu	Tỷ lệ
Được hỗ trợ đầy đủ	108	54,0%
Được hỗ trợ một phần	75	37,5%
Phần lớn không có căn cứ	17	8,5%
Ghép sai	0	0,0%




Hình 8. ROUGE F1 của bốn hệ thống trên 2.000 mẫu kiểm thử.

C. Giao thức đánh giá bằng mô hình ngôn ngữ lớn

Việc sử dụng mô hình ngôn ngữ lớn để đánh giá được xây dựng dựa trên các nghiên cứu về LLM-as-a-Judge và đánh giá sinh ngôn ngữ tự nhiên bằng bộ tiêu chí có cấu trúc. Các nghiên cứu này đồng thời cảnh báo về thiên lệch vị trí, thiên lệch độ dài và thiên lệch đối với văn bản do LLM tạo ra [15, 16].

Đánh giá hệ thống được thực hiện trên 200 văn bản nguồn, tương ứng với 800 tóm tắt ứng viên. Mô hình chấm được sử dụng là **GPT-5.6 Solar Max**. Câu lệnh, bộ tiêu chí, thang điểm và trọng số được giữ cố định trong toàn bộ quá trình đánh giá.

Với mỗi văn bản nguồn, mô hình chấm nhận bốn tóm tắt ứng viên ký hiệu A/B/C/D; tên hệ thống được làm mờ và tóm tắt tham chiếu không được cung cấp. Vị trí A/B/C/D được hoán đổi và cân bằng để mỗi hệ thống xuất hiện đúng 50 lần ở từng vị trí. Đầu ra có cấu trúc gồm điểm từ 1 đến 5 cho năm tiêu chí, điểm tổng hợp theo trọng số, nhãn lỗi nghiêm trọng về tính đúng sự thật và loại lỗi tương ứng. Thiết kế ghép cặp bảo đảm cả bốn hệ thống được chấm trên cùng mã định danh mẫu; bootstrap và so sánh từng cặp cũng được thực hiện theo mã



Hình 9. Điểm của mô hình chấm LLM theo từng tiêu chí trên 200 văn bản nguồn.

định danh này. Mô hình chấm xem đồng thời bốn tóm tắt ứng viên của cùng một văn bản nguồn trong một lượt, thay vì chấm từng ứng viên độc lập.

Nhận xét. Bảng 8 cho thấy thứ hạng theo đánh giá đối chiếu với văn bản nguồn khác đáng kể so với thứ hạng ROUGE. Lead-3 đạt điểm tổng hợp cao nhất (4,32) nhờ điểm trung thực trung bình 5,00 theo mô hình chấm và độ bao phủ cao nhất (3,42). Lợi thế này đi kèm điểm súc tích thấp nhất (4,00), cho thấy kết quả của Lead-3 được hỗ trợ một phần bởi ngân sách độ dài lớn hơn. Lead-1 có độ bao phủ thấp hơn Lead-3 nhưng vẫn đạt điểm tổng hợp 4,09 nhờ giữ nguyên văn bản nguồn và duy trì độ trôi chảy cao.

Hai mô hình sinh đạt điểm tổng hợp gần tương đương: 3,328 đối với Scratch Transformer và 3,379 đối với ViT5. Scratch Transformer có điểm trung thực cao hơn và tỷ lệ lỗi nghiêm trọng thấp hơn ViT5, lần lượt là 45,5% và 52,0%; ViT5 có lợi thế về độ trôi chảy và độ súc tích. Chênh lệch Scratch–ViT5 bằng $-0,052$, với khoảng tin cậy bootstrap 95% là $[-0,229; 0,125]$. Khoảng tin cậy chứa giá trị 0 cho thấy hai mô hình có các thế mạnh bổ sung thay vì một thứ hạng vượt trội toàn diện.

Nhận xét. Bảng 9 làm rõ sự đánh đổi giữa độ bao phủ và độ súc tích. Lead-3 có CR 29,00%, cao hơn đáng kể ba hệ thống còn lại, nhưng điểm súc

Bảng VIII. Điểm trung bình theo năm tiêu chí trên cùng 200 văn bản nguồn.

Hệ thống	Trung thực	Bao phủ	Tập trung	Trôi chảy	Súc tích	Tổng hợp
Lead-1	5,00	2,42	4,06	4,71	4,25	4,09
Lead-3	5,00	3,42	4,15	4,63	4,00	4,32
Scratch Transformer	3,39	2,16	3,62	4,10	4,47	3,33
ViT5	3,26	2,22	3,81	4,34	4,63	3,38

Bảng IX. Tỷ lệ nén và độ súc tích trên cùng 200 mẫu đánh giá bằng LLM.

Hệ thống	CR (%)	Độ súc tích
Lead-1	11,32	4,245
Lead-3	29,00	3,995
Scratch Transformer	9,42	4,470
ViT5	8,59	4,625

tích chỉ đạt 3,995, thấp nhất trong bảng. Ngược lại, ViT5 tạo đầu ra ngắn nhất, với CR 8,59%, và đạt điểm súc tích cao nhất là 4,625. Scratch Transformer nằm giữa hai xu hướng này, với CR 9,42% và điểm súc tích 4,470. Lead-1 có CR 11,32% nhưng vẫn đạt 4,245 về độ súc tích do chỉ trích xuất một câu hoàn chỉnh. CR trên 200 mẫu gần với kết quả trên 2.000 mẫu, với chênh lệch tối đa khoảng 1,15 điểm phần trăm; do đó, tập đánh giá bằng LLM có tính đại diện tương đối tốt về độ dài đầu ra. Mối liên hệ giữa CR và độ súc tích chỉ là quan sát mô tả, không được diễn giải như quan hệ nhân quả.

Bảng X. Tỷ lệ đầu ra mắc từng nhóm lỗi về tính đúng sự thật.

Loại lỗi	Scratch	ViT5
RELATION	30,5%	18,5%
PREDICATE	24,5%	25,0%
UNSUPPORTED	18,0%	31,0%
DATE_TIME	11,5%	21,5%
ENTITY	15,5%	12,0%

Các tỷ lệ trong Bảng 10 được tính trên 200 đầu ra của mỗi mô hình. Một đầu ra có thể mang nhiều nhãn lỗi, vì vậy tổng tỷ lệ có thể vượt 100%.

Nhận xét. Bảng 10 cho thấy hai mô hình có các hướng sai khác nhau. Scratch Transformer có tỷ lệ lỗi UNSUPPORTED và DATE_TIME thấp hơn ViT5 nhưng tỷ lệ lỗi RELATION cao hơn, gợi ý rằng mô hình tương đối thận trọng khi bổ sung thông tin ngoài nguồn và còn dư địa cải thiện ở biểu diễn quan hệ. Tỷ lệ PREDICATE gần như tương đương, 24,5% so với 25,0%. Vì vậy, Scratch Transformer có thể ưu tiên ràng buộc quan hệ hoặc xếp hạng lại ứng viên theo tính nhất quán cấu trúc; ViT5 có thể tăng cường kiểm chứng thông tin ngoài nguồn, đặc biệt với ngày tháng và số liệu.

VI. THẢO LUẬN

A. Khác biệt giữa xếp hạng ROUGE và LLM

ROUGE thường mức độ trùng khớp với tóm tắt tham chiếu. Scratch Transformer học được phong cách và nội dung gần tóm tắt tham chiếu nên đạt điểm cao. Ngược lại, mô hình chấm LLM đọc văn bản nguồn và đánh giá mức độ hỗ trợ của từng khẳng định. Lead-1 và Lead-3 trích nguyên văn nên ít tạo thông tin không có căn cứ, trong khi tóm tắt tham chiếu có thể chứa chi tiết không được văn bản nguồn hỗ trợ. Vì vậy, hai hệ thống Lead có thể đạt ROUGE thấp hơn nhưng có độ trung thực cao hơn rõ rệt.

B. Scratch Transformer so với ViT5

Scratch Transformer là một đối chứng huấn luyện từ đầu có tính cạnh tranh: mô hình dẫn đầu cả ba chỉ số ROUGE trên 2.000 mẫu kiểm thử, có tỷ lệ lỗi nghiêm trọng thấp hơn ViT5 và đạt điểm tổng hợp không khác biệt rõ ràng so với ViT5. ViT5 có lợi thế về độ trôi chảy và độ súc tích, còn Scratch Transformer cho phép kiểm soát đầy đủ kiến trúc, tokenizer, dữ liệu huấn luyện và quy trình suy luận. Vì vậy, ViT5 phù hợp khi ưu tiên chất lượng ngôn ngữ sẵn có, còn Scratch Transformer phù hợp cho nghiên cứu cơ chế mô hình và tối ưu theo miền dữ liệu cụ thể.

C. Hàm ý theo mục tiêu sử dụng

Không có một hệ thống tốt nhất theo mọi tiêu chí. Scratch Transformer dẫn đầu theo ROUGE và cho phép kiểm soát toàn bộ quy trình; Lead-3 đạt điểm LLM cao nhất nhưng tạo đầu ra dài hơn; ViT5 có lợi thế về độ trôi chảy và độ súc tích. Vì vậy, lựa chọn hệ thống nên gắn với ưu tiên giữa độ bao phủ, độ súc tích, mức tương đồng tham chiếu và tính đúng sự thật.

D. Phạm vi diễn giải

Các so sánh ROUGE trên 2.000 mẫu và tỷ lệ lỗi trên 200 mẫu chủ yếu mang ý nghĩa mô tả; chênh lệch điểm tổng hợp Scratch–ViT5 được báo cáo thêm khoảng tin cậy bootstrap. Đánh giá bằng LLM là nguồn bằng chứng bổ sung, không thay thế đánh giá của con người. Trong phạm vi này, Scratch Transformer thể hiện tính cạnh tranh về mức tương đồng tham chiếu và lợi thế nhất định trên các chỉ báo liên quan đến tính đúng sự thật so với ViT5.

VII. PHẠM VI NGHIÊN CỨU VÀ HƯỚNG CÙNG CỎ

Đánh giá bằng mô hình ngôn ngữ lớn được thực hiện theo thiết kế ghép cặp trên 200 mẫu, tương ứng 10% tập kiểm thử, với tên hệ thống được làm mù và vị trí ứng viên được cân bằng. Thiết kế này bổ sung cho ROUGE và hỗ trợ phân tích từng tiêu chí. Nghiên cứu tiếp theo có thể mở rộng mẫu, sử dụng thêm mô hình chấm và bổ sung đánh giá của con người để củng cố khả năng khái quát.

Kiểm tra tóm tắt tham chiếu giúp nhận diện đầu ra đúng theo văn bản nguồn nhưng không trùng với tham chiếu; vì vậy, ROUGE được dùng như thước đo mức tương đồng thay vì đại diện duy nhất cho chất lượng. Nghiên cứu hiện chưa khảo sát giao thoa giữa dữ liệu fine-tune của ViT5 và tập kiểm thử. Kết quả Lead-1 và Lead-3 cũng phù hợp nhất khi diễn giải trong miền tin tức và có thể được kiểm chứng thêm trên thể loại khác.

VIII. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Nghiên cứu đã xây dựng quy trình thống nhất để so sánh bốn hệ thống tóm tắt tin tức tiếng Việt. Scratch Transformer dẫn đầu cả ba chỉ số ROUGE và có tỷ lệ lỗi nghiêm trọng thấp hơn ViT5 trong tập đánh giá bằng mô hình ngôn ngữ lớn. ViT5 có lợi thế về độ trôi chảy và độ súc tích, nhưng chênh lệch điểm tổng hợp giữa hai mô hình sinh chưa rõ ràng theo bootstrap. Kết quả cho thấy mô hình huấn luyện từ đầu là một nền tảng cạnh tranh, minh bạch và có khả năng tùy biến cho tóm tắt tiếng Việt.

Hướng phát triển là nâng cao Scratch Transformer bằng mục tiêu huấn luyện chú trọng quan hệ ngữ nghĩa, xếp hạng lại ứng viên và kiểm chứng thực thể hoặc số liệu sau sinh. Mở rộng đánh giá

với thêm mô hình chấm và người đánh giá độc lập sẽ giúp xác nhận các lợi thế đã quan sát và định hướng tối ưu theo bối cảnh triển khai.

IX. PHÂN CÔNG VÀ ĐÓNG GÓP CỦA CÁC THÀNH VIÊN

Công việc được phân chia theo bốn khối kỹ thuật chính:

Trần Đức Thịnh – Huấn luyện Scratch Transformer. Xây dựng quy trình huấn luyện Transformer từ đầu; theo dõi hàm mất mát; lựa chọn checkpoint và thiết lập siêu tham số.

Lưu Xuân Tân – Đối sánh với ViT5. Thiết lập suy luận cho ViT5; chuẩn hóa đầu vào, đầu ra và so sánh các hệ thống trên cùng dữ liệu và chỉ số.

Đặng Minh Nhật – Đánh giá bằng ROUGE và LLM. Tính ROUGE và tỷ lệ nén; triển khai giao thức LLM làm mù tên hệ thống, cân bằng vị trí và phân tích ghép cặp.

Đặng Duy Anh – Xác thực và lựa chọn cấu hình. Đánh giá các biến thể greedy, beam search, length penalty và no-repeat n-gram trước khi cố định cấu hình kiểm thử.

PHỤ LỤC A. CHI TIẾT KỸ THUẬT CỦA SCRATCH TRANSFORMER

Luồng tensor và mask. Với batch B , độ dài nguồn S , độ dài đích T , $d = 384$ và sáu đầu attention, các tensor chính có dạng trong Bảng 11. Mask nguồn chặn khóa PAD trong encoder self-attention và decoder cross-attention; decoder self-attention sử dụng hợp của mask nhân quả và mask đệm đích.

Khối Pre-Norm. LayerNorm được đặt trước attention và FFN; decoder bổ sung cross-attention giữa masked self-attention và FFN. Final LayerNorm nằm sau chồng encoder và decoder; mỗi FFN mở

Bảng XI. Kích thước các tensor và mask chính.

Thành phần	Kích thước
ID nguồn/đích	$[B, S], [B, T]$
Embedding nguồn/đích	$[B, S, 384], [B, T, 384]$
Q, K, V sau khi tách head	$[B, 6, L, 64]$
Encoder self-attention	$[B, 6, S, S]$
Decoder self-attention	$[B, 6, T, T]$
Cross-attention	$[B, 6, T, S]$
Logit đầu ra	$[B, T, 16000]$
Mask nguồn	$[B, 1, 1, S]$
Mask đích hợp	$[B, 1, T, T]$

rộng từ 384 lên 1.536 chiều, áp dụng GELU rồi chiếu về 384 chiều.

Số tham số. Shared embedding có 6.144.000 tham số, mỗi attention module có 591.360 tham số và mỗi FFN có 1.181.568 tham số. Toàn mô hình có 30.991.872 tham số học duy nhất; các tham chiếu lặp trong state_dict và buffer vị trí không tạo thêm bậc tự do.

Huấn luyện và suy luận. Decoder được huấn luyện bằng teacher forcing; cross-entropy bỏ qua PAD và dùng label smoothing 0,05. AdamW kết hợp warmup 3.030 bước với suy giảm cosine; gradient được unscale trước khi clip tại 1,0 và được all-reduce giữa hai GPU. Khi suy luận, beam search giữ bốn giả thuyết, dùng length penalty 1,1 và chặn lặp trigram; decoder không sử dụng key-value cache.

TÀI LIỆU THAM KHẢO

- [1] A. Vaswani et al., “Attention is all you need,” in *Advances in Neural Information Processing Systems*, 2017, pp. 5998–6008.
- [2] C.-Y. Lin, “ROUGE: A package for automatic evaluation of summaries,” in *Text Summarization Branches Out*, 2004, pp. 74–81.
- [3] C. Raffel et al., “Exploring the limits of

- transfer learning with a unified text-to-text Transformer,” *J. Mach. Learn. Res.*, vol. 21, no. 140, pp. 1–67, 2020.
- [4] T. Kudo and J. Richardson, “SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing,” in *Proc. EMNLP: System Demonstrations*, 2018, pp. 66–71.
- [5] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer normalization,” arXiv:1607.06450, 2016.
- [6] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proc. ICLR*, 2019.
- [7] D. Hendrycks and K. Gimpel, “Gaussian error linear units (GELUs),” arXiv:1606.08415, 2016.
- [8] L. Phan, H. Tran, H. Nguyen, and T. H. Trinh, “ViT5: Pretrained text-to-text Transformer for Vietnamese language generation,” in *Proc. NAACL 2022 Student Research Workshop*, 2022, pp. 136–142, doi: 10.18653/v1/2022.naacl-srw.18.
- [9] VietAI, “vit5-base-vietnews-summarization,” Hugging Face model repository. [Online]. Available: <https://huggingface.co/VietAI/vit5-base-vietnews-summarization>. Accessed: Aug. 22, 2026.
- [10] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992, doi: 10.18653/v1/D19-1410.
- [11] Sentence-Transformers, “paraphrase-multilingual-mpnet-base-v2,” Hugging Face model repository. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-mpnet-base-v2>. Accessed: Aug. 22, 2026.
- [12] O. Press and L. Wolf, “Using the output embedding to improve language models,” in *Proc. 15th Conf. European Chapter of the Association for Computational Linguistics*, vol. 2, 2017, pp. 157–163.
- [13] R. Müller, S. Kornblith, and G. E. Hinton, “When does label smoothing help?” in *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 4694–4703.
- [14] Y. Wu et al., “Google’s neural machine translation system: Bridging the gap between human and machine translation,” arXiv:1609.08144, 2016.
- [15] L. Zheng et al., “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023, pp. 46595–46623.
- [16] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, “G-Eval: NLG evaluation using GPT-4 with better human alignment,” in *Proc. EMNLP*, 2023, pp. 2511–2522, doi: 10.18653/v1/2023.emnlp-main.153.