

Tóm tắt văn bản tiếng Việt

So sánh Transformer Seq2Seq xây dựng từ đầu và ViT5

Abstractive Text Summarization for Vietnamese News

Đại học Công nghệ, ĐHQGHN
[Tên học phần] – [Giảng viên hướng dẫn]
[Ngày thuyết trình]

Nhiệm vụ: Bài báo tiếng Việt (input) $\rightarrow$ hệ thống tóm tắt $\rightarrow$ bản tóm tắt ngắn gọn, đúng ý (output)

Nội dung trình bày

1. Tổng quan đề tài
2. Xử lý và chuẩn hóa dữ liệu
3. Phân tích tập dữ liệu
4. Kiến trúc mô hình Transformer
5. Phân tích Tokenizer SPM
6. Cơ chế Attention
7. Quá trình huấn luyện và Loss
8. Mở rộng thành bốn hệ thống
9. **Lựa chọn cấu hình trên validation**
10. **Đánh giá cuối trên tập test**
11. Phân tích lỗi và hạn chế
12. **Kết luận và hướng cải thiện**

Mạch trình bày

Phần đầu trình bày cách xây dựng Transformer từ đầu; phần sau trả lời ba câu hỏi: chọn cấu hình nào, so sánh hệ thống ra sao và cần cải thiện gì tiếp theo.


Tổng quan đề tài

Bài toán:

- **Task:** Tóm tắt trừu tượng (Abstractive Summarization)
- **Input:** Bài báo tiếng Việt, tối đa 768 token
- **Output:** Bản tóm tắt sinh ra
- **Mô hình lõi:** Transformer Seq2Seq xây dựng hoàn toàn từ đầu
- **Tokenizer:** SentencePiece Unigram, vocab 16.000
- **Dữ liệu sạch:** 246.975 cặp bài báo–tóm tắt

Phạm vi mở rộng của dự án:

- So sánh với Lead-1, Lead-3 và ViT5-Base
- Chọn cấu hình bằng validation, sau đó khóa trước test
- Đánh giá tự động trên cùng một tập test và cùng evaluator




Thông điệp chính

Dự án xây dựng Transformer từ đầu và thiết lập quy trình so sánh công bằng với mô hình tiền huấn luyện cùng baseline trích xuất.

Xử lý và chuẩn hóa dữ liệu

Quy trình làm sạch dữ liệu (Data Cleaning):

1. **Chuẩn hóa Unicode NFC:** thống nhất ký tự tiếng Việt, tránh lỗi encoding.
2. **Loại HTML, URL và ký tự nhiễu:** xóa thẻ, liên kết và ký tự điều khiển.
3. **Chuẩn hóa khoảng trắng, xuống dòng:** gộp khoảng trắng và dòng trống.
4. **Lọc độ dài:** bài báo 100–1.200 từ; tóm tắt 10–150 từ.
5. **Lọc Semantic Similarity:** Dùng mô hình embedding paraphrase-multilingual-mpnet-base-v2 để tính cosine similarity và giữ lại các cặp có độ tương đồng giữa source và reference $\geq 0,50$.



Thông điệp chính


Lọc tương đồng ngữ nghĩa là bước then chốt: giảm cặp nguồn–đích nhiễu trước khi mô hình học quan hệ bài báo–tóm tắt.

Phân tích tập dữ liệu

Thống kê mô tả (246.975 mẫu):

Chỉ số	Bài báo	Tóm tắt
Trung bình	467,6 từ	41,3 từ
Độ lệch chuẩn	217,5	15,8
Trung vị	432,0 từ	38,0 từ
Min	100 từ	10 từ
Max	1.200 từ	150 từ
Compression Ratio		10,62%
Cosine Similarity		0,706

- ▶ Tóm tắt dài khoảng 1/9,4 bài gốc.
- ▶ Độ tương đồng Cosine là 0,706 cho thấy mức căn chỉnh ngữ nghĩa tương đối tốt.
- ▶ Token fertility xấp xỉ 1,14, phù hợp dữ liệu báo điện tử.




Kiến trúc mô hình Transformer

Thông số kiến trúc:

Thành phần	Giá trị
Kiến trúc	Encoder–Decoder
Chuẩn hóa	Pre-Norm
Vocab size	16.000
d_{model}	384
d_{ff}	1.536 ($\times 4$)
Encoder / Decoder	6 / 6 lớp
Attention heads	6 ($d_k = 64$)
Dropout	0,1
Activation	GELU
Tie Embeddings	Có
Số tham số	49,76 triệu
Max Src / Tgt	768 / 96 token

$d_k = d_{model}/h = 384/6 = 64$. Sáu head cho phép mô hình học nhiều kiểu quan hệ ngữ nghĩa song song.



Sơ đồ Transformer Encoder–Decoder tổng quát (Vaswani et al., 2017).

Phân tích Tokenizer: SentencePiece Unigram


Thống kê tokenization:

- ▶ Loại: SentencePiece Unigram
- ▶ Vocab size: 16.000
- ▶ Mean token: Source 533,3 / Target 46,6
- ▶ Fertility: mean 1,14; median 1,13

Fertility thấp cho thấy phần lớn từ tiếng Việt được giữ gần một token; tên riêng, từ ngoại lai và ký hiệu thường bị tách thành nhiều subword.

Ví dụ tokenization:

Từ	Token SPM	f
tôi	_tôi	1,0
iPhone	_i + Phone	2,0
Samsung	_Sam + sung	2,0
COVID-19	_CO + VID + -19	3,0



Phân tích cơ chế Attention

Multi-Head Self-Attention:

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

- ▶ Q, K, V được chiếu từ $X \in \mathbb{R}^{n \times 384}$.
- ▶ $\sqrt{d_k} = \sqrt{64} = 8$ giúp softmax không bão hòa.
- ▶ 6 head học quan hệ cú pháp, tham chiếu và đồng tham chiếu.
- ▶ Decoder dùng causal mask: token i chỉ nhìn thấy $j \leq i$.

Cross-Attention:

- ▶ Q từ Decoder; K, V từ Encoder output.
- ▶ Căn chỉnh từng token đích với vùng thông tin quan trọng của nguồn.

Vì sao chọn Pre-Norm?

Post-Norm	Pre-Norm (chọn)
LN sau sublayer	LN trước sublayer
Đường truyền gradient qua nhiều tầng kém ổn định	Ổn định, thuận lợi hơn qua residual path
Nhạy learning rate	Ít nhạy hơn
Kiến trúc gốc	Phù hợp train từ đầu

Các lựa chọn khác:

- ▶ GELU; sinusoidal positional encoding
- ▶ Tie embedding và output projection
- ▶ Label smoothing 0,05

Quá trình huấn luyện và Loss


Siêu tham số:

Tham số	Giá trị
Optimizer	AdamW
Learning rate	3×10^{-4}
Weight decay	0,01
(β_1, β_2)	(0,9; 0,98)
Scheduler	Cosine + Warmup
Warmup steps	3.030
Min LR	10^{-6}
Batch size	64 (32×2 GPU)
Mixed precision	AMP (FP16)
Grad clip	$\ \nabla\ \leq 1,0$
Epochs	20; patience 4

Best checkpoint: epoch 17

Val Loss = 2,5539 $\Rightarrow$ PPL $\approx$ 12,86. Không cải thiện từ epoch 18.


Train Loss và Validation Loss qua 20 Epoch



Từ một mô hình đến phép so sánh bốn hệ thống

Câu hỏi thực nghiệm mới:

1. Scratch Transformer tốt hơn baseline trích xuất đến đâu?
2. Mô hình huấn luyện từ đầu khác ViT5 tiền huấn luyện như thế nào?
3. Cấu hình giải mã ảnh hưởng thế nào đến ROUGE và độ dài tóm tắt?
4. Kết luận trên validation có còn giữ được trên test độc lập không?



Nguyên tắc

Validation dùng để quyết định; test chỉ dùng để báo cáo kết quả cuối.

4

hệ thống

9

cấu hình validation

2.000

mẫu test lỗi

1

evaluator thống nhất

Bốn hệ thống được so sánh trên cùng đầu vào

Lead-1

Lấy **câu đầu tiên** của bài báo. Baseline đơn giản để đo mức độ “lead bias” của dữ liệu tin tức.

Lead-3

Lấy **ba câu đầu tiên**. Bao quát hơn Lead-1 nhưng thường dài và kém súc tích.

Scratch Transformer

Encoder–Decoder 6/6 lớp, 49,76M tham số, tokenizer SPM tự huấn luyện; giải mã được chọn trên validation.

ViT5-Base

VietAI/vit5-base-vietnews-summarization; đại diện cho hướng mô hình Seq2Seq tiền huấn luyện.

Thông điệp chính

Cùng ID, cùng source/reference, cùng schema prediction và cùng mã tính ROUGE giúp khác biệt quan sát được phản ánh hệ thống thay vì khác biệt pipeline.

Cách chọn cấu hình: tối ưu trên validation, không nhìn test

Biến số được khảo sát:

- ▶ **Thuật toán:** Greedy hoặc Beam Search
- ▶ **Beam size:** $B = 4$
- ▶ **Length penalty:** $\alpha \in \{0,8; 1,0; 1,1\}$
- ▶ **Chặn lặp:** `no_repeat_ngram_size=3`
- ▶ **ViT5:** giới hạn sinh `max_new_tokens=128`

Tiêu chí quyết định:

1. Ưu tiên ROUGE-1/2/L F1 trên validation.
2. Kiểm tra compression ratio để tránh cải thiện điểm chỉ nhờ sinh dài hơn.
3. Chọn một cấu hình duy nhất cho mỗi mô hình.

Đúng quy trình

Cấu hình $\rightarrow$ validation $\rightarrow$ chọn $\rightarrow$ đóng băng $\rightarrow$ test.

Không hợp lệ

Chạy nhiều cấu hình trên test rồi chọn cấu hình có điểm test cao nhất.

Smoke test 10 mẫu chỉ kiểm tra pipeline, schema và lỗi kỹ thuật; không dùng để chọn mô hình.

Scratch Transformer: Beam-4, LP=1,1 thắng cả R-1 và R-2

Kết quả validation:

Cấu hình	R-1	R-2	R-L	CR (%)
Greedy	33,0618	16,9446	27,5080	8,7365
Beam-4, LP=0,8, nr=3	33,7884	18,2143	28,4245	8,4232
Beam-4, LP=1,0, nr=3	33,9924	18,1839	28,3486	9,2057
Beam-4, LP=1,1, nr=3	34,1597	18,2425	28,3899	9,7061

- ▶ So với Greedy: +1,0979 R-1 và +1,2979 R-2.
- ▶ LP=0,8 nhỉnh hơn rất nhẹ ở R-L (+0,0346), nhưng thấp hơn ở R-1/R-2.
- ▶ LP=1,1 sinh dài hơn; do đó cần đọc cùng compression ratio.

So với Greedy

+1,0979

R-1

+1,2979

R-2

Quyết định

Chọn **Beam-4, LP=1,1, nr=3**: cân bằng tốt nhất giữa R-1, R-2 và mức bao quát.

ViT5: LP=1,1 dẫn đầu nhất quán nhưng biên thắng nhỏ

Kết quả validation:

Cấu hình	R-1	R-2	R-L	CR (%)
beam4_lp0.8_max128_nr3	31,1089	14,1935	24,6530	8,7852
beam4_lp1.0_max128_nr3	31,2016	14,2340	24,6987	8,8863
beam4_lp1.1_max128_nr3	31,2495	14,2283	24,7108	8,9242

- ▶ LP=1,1 cao nhất ở R-1 và R-L; R-2 chỉ thấp hơn LP=1,0 đúng 0,0057 điểm.
- ▶ Khi α tăng, compression ratio tăng nhẹ: mô hình bao quát thêm nhưng chưa dài quá mức.
- ▶ Chênh lệch nhỏ cho thấy ViT5 ít nhạy với LP trong khoảng khảo sát.

Biên độ LP=1,1 so với LP=0,8

+0,1406

R-1

+0,0578

R-L

Quyết định

Chọn

beam4_lp1.1_max128_nr3;

lợi thế nhỏ nhưng ổn định trên hai trong ba ROUGE.


Toàn bộ 9 cấu hình validation trong một bảng

Hệ	Cấu hình	R-1	R-2	R-L	CR (%)
Scratch	Greedy	33,0618	16,9446	27,5080	8,7365
	Beam-4 LP=0,8 nr=3	33,7884	18,2143	28,4245	8,4232
	Beam-4 LP=1,0 nr=3	33,9924	18,1839	28,3486	9,2057
	Beam-4 LP=1,1 nr=3	34,1597	18,2425	28,3899	9,7061
ViT5	beam4_lp0.8_max128_nr3	31,1089	14,1935	24,6530	8,7852
	beam4_lp1.0_max128_nr3	31,2016	14,2340	24,6987	8,8863
	beam4_lp1.1_max128_nr3	31,2495	14,2283	24,7108	8,9242
Baseline	Lead-1	25,6098	11,0876	19,6637	11,0935
Baseline	Lead-3	24,9105	10,6417	17,5409	29,7882

Quan sát 1: cả hai mô hình sinh đều vượt rõ rệt hai baseline trên validation.

Quan sát 2: Lead-3 dài gần 30% bài gốc nhưng ROUGE thấp hơn Lead-1, nên “dài hơn” không đồng nghĩa “tốt hơn”.

Cấu hình Scratch được chọn vượt ViT5 rõ nhất ở ROUGE-2



Khoảng cách Scratch – ViT5:


Thước đo	Δ điểm
ROUGE-1	+2,9102
ROUGE-2	+4,0142
ROUGE-L	+3,6791

- ▶ R-2 tăng mạnh nhất: Scratch khớp tốt hơn ở mức cụm hai token.
- ▶ Scratch cũng sinh dài hơn: CR 9,7061% so với 8,9242%.
- ▶ Vì vậy cần xác nhận trên test và phân tích độ dài trước khi kết luận tổng quát.

Thông điệp chính

Validation ủng hộ Scratch Transformer, nhưng test độc lập mới quyết định liệu lợi thế này có bền vững hay không.

Compression ratio giúp đọc ROUGE đúng ngữ cảnh



Cách diễn giải:

- ▶ **Lead-3** dài nhất nhưng ROUGE thấp nhất: thêm nhiều câu đầu không bảo đảm đúng trọng tâm.
- ▶ **ViT5** súc tích nhất trong hai mô hình sinh.
- ▶ **Scratch** dài hơn ViT5 khoảng 0,78 điểm phần trăm và đạt ROUGE cao hơn.
- ▶ ROUGE cần được đọc cùng độ dài, repetition và ví dụ đầu ra.

CR ở đây được tính theo tỉ lệ độ dài tóm tắt sinh ra so với bài báo nguồn trên cùng tập validation.

Hai cấu hình được đóng băng trước khi chạy test

Scratch Transformer

Cấu hình: Beam-4, LP=1,1, nr=3

- ▶ Checkpoint tốt nhất: epoch 17
- ▶ Tokenizer: SentencePiece Unigram 16K
- ▶ Beam size: 4
- ▶ Length penalty: 1,1
- ▶ No-repeat n-gram: 3

ViT5-Base

Cấu hình: beam4_lp1.1_max128_nr3

- ▶ Model: VietAI/vit5-base-vietnews-summarization
- ▶ Beam size: 4
- ▶ Length penalty: 1,1
- ▶ Max new tokens: 128
- ▶ No-repeat n-gram: 3

Điểm khóa của thực nghiệm

Sau slide này, mọi kết quả test phải được sinh bằng đúng hai cấu hình trên. Không điều chỉnh cấu hình sau khi xem test.

Đánh giá hai tầng: ROUGE và LLM judge

Đánh giá tự động trên toàn bộ test

2.000 source × 4 hệ thống

- ▶ ROUGE-1/2/L F1 theo cùng pipeline Unicode
- ▶ Compression ratio và độ dài đầu ra
- ▶ Cùng ID, cùng evaluator, cấu hình đã đóng băng

Hỏi: Prediction giống reference đến mức nào?

Đánh giá source-grounded bằng LLM

200 source × 4 hệ thống

- ▶ 20 batch, mỗi batch gồm 10 source
- ▶ Ẩn tên hệ thống và không cung cấp reference
- ▶ Chấm 5 tiêu chí và gắn nhãn lỗi factuality

Hỏi: Tóm tắt có đúng, đủ và dễ đọc so với source không?

Nguyên tắc diễn giải

ROUGE và LLM judge là hai nguồn bằng chứng bổ sung; không thước đo nào tự nó đủ để kết luận chất lượng tóm tắt.

ROUGE ưu tiên Scratch Transformer trên 2.000 mẫu

Kết quả trên toàn bộ tập test:


Hệ thống	N	R-1	R-2	R-L	CR (%)
Lead-1	2.000	26,78	12,17	20,80	11,51
Lead-3	2.000	25,12	11,03	17,92	30,14
Scratch Transformer	2.000	33,84	17,84	28,30	9,42
ViT5-Base	2.000	31,22	14,51	25,00	8,63

Quan sát: Scratch đạt ROUGE cao nhất trên cả ba thước đo; ViT5 đứng thứ hai. Lead-3 sinh dài nhất nhưng có ROUGE thấp hơn Lead-1.

Kết luận theo ROUGE

Scratch có độ trùng với reference cao nhất. Kết quả này chưa chứng minh prediction đúng sự thật, bao phủ đủ ý hay không chứa thông tin suy diễn.

So sánh ROUGE trên test_core_2000



Thước đo chính: mức trùng n-gram với reference.

LLM judge mù danh tính đánh giá trực tiếp theo source

1. Input

01 source + 04 candidate summaries ký hiệu A/B/C/D.

2. Làm mù và cân bằng

Ẩn tên mô hình, bỏ reference; mỗi hệ thống xuất hiện 50 lần tại từng vị trí A/B/C/D.

3. Output có cấu trúc

Điểm 1–5, Overall có trọng số, cờ major factual error và loại lỗi.

20 batch × 10 source = 200 source

4 hệ thống × 200 source = 800 summaries

Rubric chấm điểm:


Tiêu chí	Trọng số
Faithfulness	35%
Coverage	25%
Focus	15%
Fluency	15%
Conciseness	10%

Vai trò của LLM judge

Đây là phép đánh giá bổ sung dựa trên source, không phải ground truth và không thay thế hoàn toàn đánh giá của con người.

LLM judge đảo thứ hạng: Lead-3 dẫn đầu

Điểm Overall trung bình và bootstrap 95% CI:



Major factual error:

Hệ thống	Tỷ lệ
Lead-3	0/200 quan sát
Lead-1	0/200 quan sát
Scratch	91/200 = 45,5%
ViT5	104/200 = 52,0%

Lead-3 vs Lead-1: +0,226, CI [0,168; 0,289].

ViT5 vs Scratch: +0,052, CI [-0,125; 0,229]; chưa khác biệt rõ.

Kết luận theo rubric hiện tại

Lead-3 đạt Overall cao nhất trên 200 mẫu; ViT5 và Scratch tương đương trong phạm vi mẫu thay vì có một mô hình thắng rõ ràng.

Mô hình sinh súc tích, nhưng factuality là điểm nghẽn

Điểm trung bình theo từng tiêu chí:

Hệ thống	Faith.	Cover.	Focus	Fluency	Concise
Lead-1	4,995	2,420	4,060	4,710	4,245
Lead-3	5,000	3,415	4,145	4,630	3,995
Scratch	3,385	2,155	3,620	4,095	4,470
ViT5	3,255	2,220	3,810	4,340	4,625

- ▶ Lead-3 dẫn đầu nhờ Faithfulness và Coverage.
- ▶ ViT5 trôi chảy và súc tích hơn Scratch.
- ▶ Hai mô hình sinh vẫn thấp hơn rõ ở Faithfulness.

Trade-off chính

Fluency và Conciseness tốt không bù được rủi ro factuality; cải thiện tiếp theo cần tập trung vào độ trung thực với source.

Ba loại lỗi phổ biến nhất:

Scratch Transformer

1. Sai quan hệ: **30,5%**
2. Sai predicate: **24,5%**
3. Không được source hỗ trợ: **18,0%**

ViT5-Base

1. Không được source hỗ trợ: **31,0%**
2. Sai predicate: **25,0%**
3. Sai ngày/thời gian: **21,5%**

ROUGE và LLM judge trả lời hai câu hỏi khác nhau

ROUGE trên 2.000 mẫu

Đo: mức trùng n-gram với reference.

Xếp hạng:

Scratch > **ViT5** > **Lead-1** > **Lead-3**

Cho thấy:

Scratch tái tạo từ ngữ và nội dung của reference tốt nhất.

Giới hạn:

Nhạy với cách diễn đạt, reference nhiễu và lead bias.

LLM judge trên 200 mẫu

Đo: mức đúng, đủ và tập trung so với source.

Xếp hạng:

Lead-3 > **Lead-1** > **ViT5** $\approx$ **Scratch**

Cho thấy:

Baseline trích xuất giữ thông tin đáng tin cậy hơn trong rubric hiện tại.

Giới hạn:

Có thể chịu thiên lệch độ dài, extractive bias và đặc tính của judge.

Tổng hợp bằng chứng

Scratch khớp reference tốt nhất nhưng không đáng tin cậy nhất theo LLM judge. Sự đảo thứ hạng cho thấy kết luận phụ thuộc trực tiếp vào câu hỏi mà thước đo đang trả lời.

LLM judge được kiểm soát và dùng làm evaluator chính


Thành phần	Thiết kế đã thực hiện	Ý nghĩa
Judge mạnh và rubric cố định	GPT-5.6 Solar Max; cùng prompt, tiêu chí và trọng số cho cả 20 batch	Đọc source kỹ, phát hiện lỗi và duy trì cách chấm thống nhất
Làm mù và cân bằng vị trí	Ẩn tên hệ thống, bỏ reference; vị trí A/B/C/D được đảo và cân bằng	Hạn chế thiên kiến theo tên mô hình và vị trí candidate
Mỗi batch là một chat mới	10 source và 40 candidate summaries mỗi chat; tắt cá nhân hóa	Hạn chế ảnh hưởng lịch sử hội thoại và giữ lượng nội dung vừa phải
Paired design trên 200 source	Bốn hệ thống được chấm trên cùng ID; dùng bootstrap và paired comparison	So sánh công bằng và định lượng độ bất định của chênh lệch

$$20 \text{ chat độc lập} \times 10 \text{ source} \Rightarrow 200 \text{ source} \times 4 \text{ hệ thống} = 800 \text{ summaries}$$

Vai trò của đánh giá người

LLM judge là evaluator source-grounded chính. Con người, nếu kiểm tra một tập con, chỉ audit xem lập luận và nhấn lỗi có bám source hay không; không mặc định là ground truth hoặc luôn tốt hơn LLM.

CR cho thấy trade-off rõ giữa Coverage và Conciseness



CR và Conciseness trên cùng 200 mẫu

Hệ thống	CR	Conc.
Lead-1	11,32%	4,245
Lead-3	29,00%	3,995
Scratch	9,42%	4,470
ViT5	8,59%	4,625

Diễn giải

CR trên 200 mẫu gần khớp 2.000 mẫu (chênh tối đa **1,15 điểm phần trăm**).
Conciseness giảm khi CR tăng; Coverage cao của Lead-3 một phần đến từ output dài hơn. Đây là trade-off trong rubric, chưa phải bằng chứng thiên vị.

Kết luận: không có hệ thống thắng trên mọi tiêu chí

01

ROUGE

Scratch đạt độ trùng với reference cao nhất trên 2.000 mẫu test.

02

LLM judge

Lead-3 dẫn đầu trên 200 mẫu; ViT5 và Scratch chưa khác rõ về Overall.

03

Bài học đánh giá

Độ trùng, độ dài, factuality và đánh giá người phải được đọc cùng nhau.

Kết luận trung tâm

Scratch khớp reference tốt nhất; Lead-3 mạnh nhất theo LLM source-grounded hiện tại; ViT5 diễn đạt trôi chảy và súc tích hơn Scratch nhưng chưa vượt rõ về Overall. Vì vậy, một điểm ROUGE đơn lẻ không đủ để kết luận chất lượng tóm tắt.

Cảm ơn thầy cô và các bạn đã lắng nghe!